



# Progetto Modelli Probabilistici per le Decisioni Smart House

1819-1-F1801Q127, Modelli Probabilistici per le Decisioni, 2018-2019

Università degli Studi di Milano Bicocca

Dipartimento di Informatica, Sistemistica e Comunicazione

Caselli Alex 807129

Villa Giacomo 807462

9 Luglio 2019


# Indice

<b>1</b>	<b>Introduzione al problema</b>	<b>3</b>
1.1	Motivazioni . . . . .	3
1.2	I dataset . . . . .	3
1.2.1	Casa A . . . . .	4
1.2.2	Casa B . . . . .	10
<b>2</b>	<b>Scelte di design e descrizione del Modello</b>	<b>16</b>
2.1	Introduzione . . . . .	16
2.2	Modello . . . . .	16
2.3	Probabilità iniziali, matrice di transizione e matrice delle emissioni . . . .	16
2.4	Ipotesi modello stazionario e ipotesi di Markov . . . . .	17
<b>3</b>	<b>Testing e Risultati</b>	<b>19</b>
3.1	Introduzione . . . . .	19
3.2	Casa A . . . . .	19
3.2.1	Numerosità Train set e Test set . . . . .	19
3.2.2	Performance . . . . .	20
3.3	Casa B . . . . .	21
3.3.1	Numerosità Train set e Test set . . . . .	21
3.3.2	Performance . . . . .	22
<b>4</b>	<b>Conclusioni e possibili sviluppi futuri</b>	<b>25</b>

# 1 Introduzione al problema

## 1.1 Motivazioni

Con l'avvento della tecnologia e dell'*IoT* è ora possibile ottenere una **grandissima mole di dati da oggetti** che non per forza sono nati come fonti di questi. In questo contesto rientrano anche tutti quei **device** e **sensori** che permettono di creare le cosiddette “*smart house*”, fornendo tutta una **serie di servizi** che spaziano dalla gestione delle luci, alla sicurezza, all'irrigazione automatica in funzione del tempo e molto altro ancora.



In questo contesto si può posizionare il nostro progetto, con un occhio di riguardo a ciò che concerne il *monitoraggio dell'individuo*. Difatti, come a breve mostreremo, siamo dotati di una serie di dati raccolti da dei sensori in una casa, in funzione di questi è necessario **inferire sull'attività** dell'individuo al fine di monitorarlo. Pensiamo a un genitore anziano che vive da solo, potrebbe essere interesse dei figli avere un sistema di monitoraggio per capire se sta bene, cosa sta facendo; ma ancora un genitore che lascia il figlio solo a casa, potrebbe essere nell'interesse del genitore essere a conoscenza delle azioni di questo.

## 1.2 I dataset

A livello di dati **siamo dotati di due case**, che da questo momento in avanti chiameremo Casa A e Casa B. Per entrambi siamo dotati di due **dataset** in formato `.txt`:

- **Attività**: un insieme di attività le quali sono identificate da un **tempo di inizio** e uno di **fine**, vi è inoltre un'**etichetta** a denotare la tipologia di attività.
- **Azioni**: un insieme di azioni identificate da un **tempo di inizio**, uno di **fine**, una **location**, una **tipologia** e il nome della **stanza** dove si svolgono. Sono sostanzialmente le informazioni riguardanti i sensori, i dati generati da questi.

I dati sono generati, per entrambe le case, da un individuo in un determinato periodo di tempo; *non tutti i sensori sono condivisi tra le due case*. Passiamo ora all'analisi del dettaglio di ognuna di queste.

### 1.2.1 Casa A

Per la **Casa A** siamo dotati di informazioni per un periodo totale di **14 giorni**, le attività in nostro possesso sono nove: *Leaving*, *Toileting*, *Showering*, *Sleeping*, *Breakfast*, *Lunch*, *Snack*, *Spare\_Time/TV* e *Grooming*.

Dati i file di descrizione presenti insieme a quelli dei dataset, **viene notificata la presenza dell'attività *Dinner***; osservando però i dati riguardanti questa casa **non vi è traccia di questa attività**, per tanto non è stata considerata.

Per quanto riguarda i sensori questi sono un totale di **12 sensori** di cui:

- **PIR**: Shower, Basin, Cooktop.
- **Magnetic**: Maindoor, Fridge, Cabinet, Cupboard.
- **Flush**: Toilet
- **Pressure**: Seat, Bed.
- **Electric**: Microwave, Toaster.

I sensori sono installati nella seguenti stanze con la seguente logica:




Figura 1: Sensori installati nella Casa A

L'attività di *preprocessing* ha visto la necessità di **unire i dataset** di attività e azioni al fine di poter etichettare le azioni con le relative attività. Siamo partiti da un **file delle attività** con **248** di queste e un file delle azioni con 409 azioni. Abbiamo ottenuto infine un dataset contenente 391 azioni etichettate, presentiamo ora la logica con la quale abbiamo affrontato questa fase di preprocessing e le relative problematiche.

**Preprocessing** Una prima fase in comune tra le due situazioni riguarda il preprocessing, difatti non eravamo dotati di un vero e proprio dataset; **è stato necessario etichettare le azioni registrate con le relative attività**, così da poter poi rendere possibile la definizione delle matrici per il modello. Abbiamo proceduto quindi a **convertire tempo di inizio e fine delle attività e delle azioni** in secondi (abbiamo valutato solo secondi, minuti e ore) , così da poter effettuare i controlli e osservare quali azioni erano all'interno di quali attività. Le casistiche studiate e gestite sono le seguenti:

**Caso A** Il **caso A** è il più semplice da risolvere e si presenta in due modalità leggermente diverse:

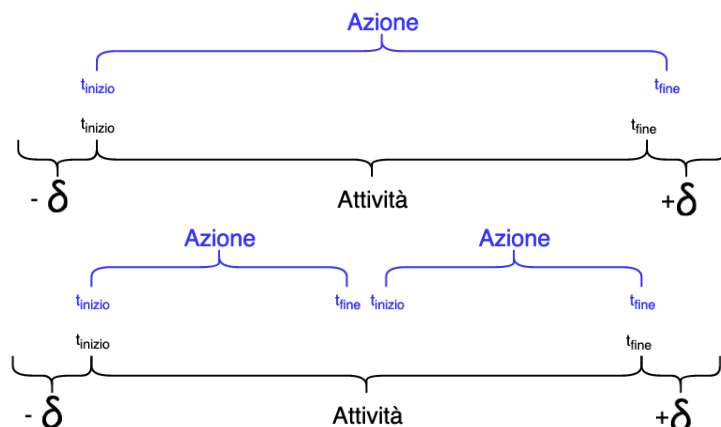


Figura 2: Caso A di etichettamento

Situazione più semplice e **relativamente maggioritaria**, vi è un'attività che vede al suo interno uno o più azioni; abbiamo quindi che il  $t_{inizio} - \delta$  dell'attività risulta essere minore uguale del  $t_{inizio}$  dell'azione ed il  $t_{fine} + \delta$  dell'attività risulta essere maggiore uguale del  $t_{fine}$  dell'azione. Il valore  $\delta$  è stato fondamentale in quanto **l'inizio (o fine) dell'azione non corrispondeva perfettamente con l'inizio (o fine) dell'attività**, vi era una qualche decina di secondo di scarto. In accordo a quanto detto si è proceduto all'etichettamento delle azioni.

**Caso B** Il caso B risulta essere **relativamente più complesso** rispetto a ciò mostrato precedentemente, è stato per tanto necessario effettuare una serie maggiore di controlli:



Figura 3: Caso B di etichettamento

In questa situazione una certa attività risultava a cavallo tra un giorno e l'altro, dunque **le semplici valutazioni precedenti non poteva bastare**, in quanto il  $t_{fine} + \delta$  dell'attività poteva non risultare più maggiore uguale al  $t_{fine}$  di un'azione iniziata nel range dell'attività considerata ma terminata prima dello scoccare della mezzanotte.

In maniera speculare può non risultare più vero che il  $t_{inizio} - \delta$  dell'attività è minore uguale del  $t_{inizio}$  dell'azione in quanto questa è iniziata dopo la mezzanotte ma all'interno del range dell'attività considerata.

Azioni anch'esse a cavallo tra i due giorni non causano difficoltà alcuna, sulle stesse un approccio basato sul **Caso A** risolve la situazione.

Dunque abbiamo dovuto considerare il giorno di inizio e fine attività ( $gAtt_{inizio}$  e  $gAtt_{fine}$ ) e il giorno di inizio e fine dell'azione ( $gAzi_{inizio}$  e  $gAzi_{fine}$ ). Abbiamo gestito le due tipologie di azioni come segue:

- **Attività giorno prima:** se  $t_{inizio} - \delta$  dell'attività risulta essere minore uguale del  $t_{inizio}$  dell'azione, ma il  $t_{fine} + \delta$  dell'attività non è maggiore uguale del  $t_{fine}$  dell'azione si valuta se  $gAtt_{inizio}$  è uguale al  $gAzi_{inizio}$  e se risulta vero che  $gAtt_{fine}$  è uguale a  $gAzi_{fine} + 1$ . In caso positivo si etichetta.
- **Attività giorno dopo:** se il  $t_{inizio} - \delta$  dell'attività non è minore uguale del  $t_{inizio}$  dell'azione ma il  $t_{fine} + \delta$  dell'attività è maggiore uguale del  $t_{fine}$  si valuta se il  $gAtt_{fine}$  è uguale a  $gAzi_{fine}$  e il  $gAzi_{inizio}$  è uguale a  $gAtt_{inizio} + 1$ . In caso positivo si etichetta.

**Caso C** Il caso C risulta essere il **più raro e il più problematico**, sostanzialmente il cambio del giorno comporta anche il cambio del mese:



Figura 4: Caso C di etichettamento

Il caso C rende necessarie delle valutazioni riguardanti non più il giorno ma il mese di inizio e fine. Dunque, in maniera analoga a quanto fatto precedentemente, abbiamo gestito e valutato in funzione anche del mese al posto del giorno.

A questo punto siamo riusciti ad **etichettare correttamente 391 attività su 409**; i motivi per cui non siamo riusciti ad etichettarne 18 sono i seguenti:

- Vi erano **azioni effettuate mentre l'individuo monitorato si trovava fuori casa** (ultima attività Leaving associata all'apertura della porta).
- Vi erano **azioni a metà tra due attività distanti** da queste di qualche ora, abbiamo deciso di non etichettarle.

Una volta ottenuto il dataset abbiamo effettuato **analisi dati** in nostro possesso per avere una prima panoramica di questi:




Figura 5: Azioni registrate

Possiamo già da questi dati ipotizzare che il soggetto analizzato sia un **individuo molto sedentario** in quanto l'azione principale registrata riguarda il stare seduto in sala; inoltre possiamo osservare un numero limitato di uscite date le azioni registrate sulla porta. Inoltre possiamo notare che la terza azione per numerosità è l'apertura del frigorifero. Informazioni aggiuntive potrebbero aiutarci a capire quanto l'individuo è sedentario e dunque poter inferire sullo stile di vita. In generale le **azioni registrate non hanno una numerosità uniforme**.

Abbiamo poi valutato anche la **numerosità delle attività registrate** per farci un'idea delle possibili difficoltà che potremmo incontrare data una possibile situazione di sbilanciamento:





Figura 6: Attività registrate

Possiamo notare una situazione di **profondo sbilanciamento**, attività quali *Snack*,


*Sleeping* e *Showering* sono una quantità molto ridotta. Possiamo comunque notare che l'attività principale è *Spare\_Time/TV* e a seguire attività quali *Toileting* e *Breakfast*. Risulta ora **necessario valutare come le azioni registrate si regolano a tali attività** al fine di avere una visione più generale della realtà analizzata.

Abbiamo quindi valutato le varie **corrispondenze tra le azioni registrate e le attività associate** a queste:


Breakfast




Grooming




Leaving




Lunch




Showering




Sleeping



Snack



Spare\_Time/TV









Figura 7: Azioni etichettate dalle attività

Possiamo notare che vi sono alcune attività quali *Spare\_Time/TV*, *Showering*, *Sleeping*, *Leaving* che vedono **un'unica azione che le contraddistingue**; dato il modello, che verrà spiegato successivamente, **questa situazione facilita di molto l'identificazione** di tali attività. Avremo invece probabilmente **problemi** a etichettare correttamente azioni come *BasinPirBathroom* in quanto occorrono in maniera predominante per l'attività *Grooming* e hanno una buona presenza anche per l'attività di *Toileting*. Discorso analogo può essere fatto per le attività di *Breakfast* e *Lunch*. Queste misure sono di fatto andranno a comporre la nostra **matrice delle osservazioni** (ne sono di fatto le righe).

Infine abbiamo analizzato la **sequenzialità delle attività**, dunque data un'attività che attività succede quella analizzata. Di fatto le immagini rappresentano le righe della **matrice di transizione**:






Figura 8: Data un'attività le attività che la succedono

Possiamo fin da subito notare come **non sia possibile passare da tutte le attività in tutte le altre attività**, sembra che vi sia come un percorso obbligato da un'attività a un'altra (vedi caso *Showering* nei confronti di *Breakfast*). **Tale situazione non ci sembra molto corretta**, ma anzi ci pare causata principalmente dalla quantità relativamente bassa di dati; verrà per tanto ulteriormente commentata nella sezione 2.3 di tale documentazione.

Possiamo notare che vi sono altre situazioni, concettualmente, più corrette come *Toileting* e *Spare Time*.

### 1.2.2 Casa B

Per la Casa B siamo dotati di informazioni riguardanti **21 giorni**, le **attività sono analoghe a quelle precedentemente mostrate** per la Casa A; qui però osserviamo anche l'attività *Dinner* che nel precedente caso non era presente.

Per quanto riguarda i **sensori** ve ne sono **12**, leggermente diversi da prima:

- **PIR:** Shower, Basin, Door Kitchen, Door Bathroom, Door Bedroom.
- **Magnetic:** Maindoor, Fridge, Cupboard.
- **Flush:** Toilet.
- **Pressure:** Seat, Bed.
- **Electric:** Microwave.

I sensori sono installati nella seguenti stanze con la seguente logica:




Figura 9: Sensori installati nella Casa B

La fase di preprocessing segue le linee di quello che è stato fatto con la Casa A; date le **2236 azioni** registrate dai sensori siamo riusciti ad etichettarne solo **1307**. Questo è dovuto al fatto che nelle attività della Casa B vi era un **problema di fondo**: tutte le attività iniziavano al tempo HH:MM:00 e terminavano al tempo HH:MM:59 le azioni invece avevano un andamento simile a quello precedentemente analizzato per la Casa A. Abbiamo pertanto utilizzato lo stesso algoritmo di prima lavorando sul  $\delta$  e sistemato gli isolati casi nel quale non si riusciva ad etichettare un'azione in quanto l'attività associata terminava prima che l'azione terminasse; lavorare solo sul  $\delta$  causava dei matching scorretti. Inoltre in questo secondo dataset **vi era una quantità considerevole di azioni completamente al di fuori delle attività presenti** (solitamente queste azioni erano costituite dall'attraversamento delle porte). Il numero finale di elementi è ritenuto comunque sufficiente se confrontato con quello ottenuto con il modello precedente.

In maniera analoga a quanto mostrato prima abbiamo effettuato una **prima attività di analisi dei dati** per ottenere una panoramica di questi:




Figura 10: Azioni registrate

Possiamo osservare come la **presenza delle nuove azioni caratterizzate dai sensori sulle porte**, sia **protagonista** per i dati raccolti in questa seconda casa. Possiamo già immaginare una **realtà relativamente più dinamica** dato il continuo movimento tra un ambiente ed un altro che in questo frangente viene registrato. Il movimento principale sembra poi essere tra la sala e la cucina.

Per quanto riguarda le azioni osserviamo la seguente suddivisione (di fatto le nostre **probabilità iniziali**):





Figura 11: Azioni registrate


Possiamo notare come, in maniera analoga a quanto osservato per la **Casa A**, vi sia **presente una realtà molto sbilanciata** a favore di determinate attività; possiamo notare come solo *Spare\_Time/TV* rappresenti da sola il 33%. Attività come *Showering* non arriva nemmeno al 1%, tuttavia le osservazioni possono limare tale situazione e permettere comunque una buona attività di inferenza.

Siamo passati poi, in maniera analoga a quanto fatto precedentemente, all'**analisi delle corrispondenze tra le azioni registrate e le attività associate** a queste:


**Breakfast**




**Dinner**




**Grooming**




**Leaving**




**Lunch**




**Showering**



**Sleeping**



**Snack**







Figura 12: Azioni etichettate dalle attività

Osserviamo come vi sia **solo un'attività la quale è caratterizzata da solo un'azione** (tale *Showering* con *ShoweringPirBathroom*); possiamo altresì notare come i **sensori presenti sulle porte siano attivati in diverse attività**, inoltre pare che l'individuo si muova molto durante ognuna di queste. Per esempio durante le attività quali *Lunch*, *Dinner* e *Breakfast* passa tra la cucina e sala più volte; possiamo ipotizzare che questa tripletta di attività unite a *Snack* possano essere difficili da identificare.

In ultimo abbiamo valutato la **sequenzialità delle attività**, di fatto abbiamo analizzato la matrice di transizione per la Casa B:






Figura 13: Data un'attività le attività che la succedono

A differenza di prima osserviamo che, nella maggior parte dei casi, è **possibile passare con probabilità più o meno alte da ogni stato a ogni altro**. Vi sono comunque attività che non permettono il passaggio ad ogni altra per esempio *Showering* e *Lunch*. In generale però la maggior numerosità del dataset consente di avere a che fare con una **situazione più realistica** di passaggio da attività in attività

## 2 Scelte di design e descrizione del Modello

### 2.1 Introduzione

Vogliamo sottolineare fin da subito che, a causa della differenza tra i sensori, **è stato necessario definire due diversi modelli** a causa delle ovvie differenze in funzione delle osservazioni; tale scelta è peraltro ulteriormente motivata dalla presenza di un'attività in più data la Casa B (tale *Dinner*).

**Tale differenza non ha dunque permesso nessun tipo di confronto significativo tra i due modelli**, in quanto questi funzionano e hanno senso solo data l'abitazione a loro associata. Tuttavia le considerazioni a livello di design sono comuni a entrambi i modelli.

### 2.2 Modello

Il **modello utilizzato** per rappresentare entrambe le realtà di interesse è un **HMM** (**H**idden **M**arkov **M**odel), tale scelta è motivata dal fatto che il problema vede il tempo come variabile; abbiamo quindi potuto modellare tale variabile.

A livello di dataset non abbiamo il timestamp delle attività in quanto questa informazione è presente nella strutturazione del dataset stesso; **l'ordine sequenziale con il quale le azioni etichettate appaiono è difatti l'ordine temporale secondo il quale queste hanno atto.**

Per quanto riguarda la modellazione:

- **Stati nascosti:** come stati nascosti sui quali intendiamo inferire abbiamo, ovviamente, le attività effettuate dall'individuo nel periodo di tempo analizzato.
- **Osservazioni:** come osservazioni abbiamo i dati rilevati dai sensori, date le tre informazioni legate a questi (*place, location, room*) abbiamo notato come queste risultino essere costanti. Di conseguenza osserviamo di avere triplette univoche dati i sensori (per entrambe le case abbiamo un totale di 12 sensori); di conseguenza modelliamo come osservazione la tripletta di informazioni fornite dal sensore stesso.

Per implementare tale modello è stata utilizzata la **libreria *hmmlearn***, in particolare abbiamo utilizzato il modello denominato ***MultinomialHMM*** in quanto dotati di emissioni discrete. Il linguaggio di programmazione utilizzato è *Python3.7*

### 2.3 Probabilità iniziali, matrice di transizione e matrice delle emissioni

Introduciamo ora le modalità con le quali sono state costruite le strutture titolo di tale sezione, le stesse rappresentano il core del nostro modello.

**Vettore delle probabilità iniziali** Tale vettore serve ad indicare la **probabilità iniziale** di trovarsi in un determinato stato, dunque nel nostro caso di performare



inizialmente una determinata attività. Per ottenere tale struttura **abbiamo osservato il numero di occorrenze delle varie attività nel dataset finale**, quello con le attività etichettate; in funzione dunque della numerosità denotata in forma di percentuale abbiamo definito questo vettore.

**Matrice di transizione** Per tale matrice abbiamo osservato, dato il dataset finale, la **successioni di attività date le etichette di queste**. Dunque abbiamo rappresentato tale conteggio sotto forma di percentuale e abbiamo ottenuto tale struttura. Tuttavia ci siamo resi conto di come, soprattutto per la *Casa A*, vi fossero per determinate azioni dei percorsi più o meno obbligati; per esempio non risultava possibile che l'attività di *Breakfast* fosse performata se prima non si fosse effettuata l'attività *Showering*. Tale situazioni non ci sembrava propriamente corretta, **riteniamo sia preferibile fornire una probabilità, seppur minima, di passaggio da un'attività a una qualsiasi altra**.

Abbiamo dunque deciso, prima di effettuare la normalizzazione della matrice di transizione, di inserire un 1 là dove fosse stato presente uno 0. Ovviamente, al fine di permettere una corretta normalizzazione, abbiamo provveduto a conteggiare i vari inserimenti fittizi. A questo punto **risulterà possibile passare, con una probabilità bassa, a qualsiasi attività**.

**Matrice delle osservazioni** Per la creazione di quest'ultima matrice abbiamo effettuato un **conteggio, attività-based, date le azioni**. Dunque, per ogni attività, abbiamo conteggiato i sensori (dunque le azioni) con i quali l'individuo monitorato interagiva. Abbiamo notato come, **per determinate attività**, vi fosse **solo un sensore che permetta a queste di scattare**; di conseguenza, a livello di calcolo delle probabilità, presentiamo per certe attività (vedi *Showering* o *Leaving*) date certe azioni registrate, situazioni deterministiche con probabilità pari a 1.

**Abbiamo accettato tale situazione**, in quanto ci sembrava scorretto eseguire un inserimento fittizio come prima; questo perché ritenevamo concettualmente scorretto che, osservando attività come *ShowerPIRBathroom*, vi potesse essere la probabilità (anche con valore bassissimo) di star performando un'attività che non fosse quella di *Showering*.

## 2.4 Ipotesi modello stazionario e ipotesi di Markov

Ultime scelte di design per quanto riguarda i modelli di entrambe le abitazioni riguardano l'**ipotesi di modello stazionario** e l'**ipotesi di Markov**.

**Ipotesi modello Stazionario** In funzione di ciò che ci è stato in classe spiegato è stato deciso di basarsi sull'**ipotesi di modello stazionario**; dunque **la matrice di transizione calcolata** in funzione del dataset (sia per la fase di testing, sia per la fase di messa a regime) **è fissa e dunque non varia mai**.

**Ipotesi di Markov** Vale per i modelli da noi creati l'**ipotesi di Markov del primo ordine**, risulterà pertanto vero che:

$$P(X_{t+1} = i_{t+1} | X_t = i_t, X_{t-1} = i_{t-1}, \dots, X_1 = i_1) = P(X_{t+1} = i_{t+1} | X_t = i_t)$$

Dunque la probabilità di uno stato successivo dipenderà solo dallo stato precedente.

## 3 Testing e Risultati

### 3.1 Introduzione

Per la fase di **training** e di **testing** abbiamo provveduto a una **divisione 70% e 30% dei dataset**, questo è stato reso **necessario per permettere una consequenzialità delle azioni** che, con altri approcci (vedi 10-fold CV), andrebbe persa.

Abbiamo quindi **calcolato vettore delle probabilità iniziali, matrice di transizione e di emissione delle osservazioni sul 70%**; in seguito abbiamo, per ogni modello dunque per ogni casa, **dato in input al modello le osservazioni questo restituisce per ognuna di queste le probabilità per ogni stato nascosto**. Abbiamo dunque provveduto ad etichettare in funzione dell'attività che presentava una probabilità più alta.

Date quindi le attività inferite dal nostro modello abbiamo provveduto al calcolo delle **principali misure di performance** quali *Accuracy*, *Precision*, *Recall* e *F-Measure*.

### 3.2 Casa A

#### 3.2.1 Numerosità Train set e Test set

Per quanto riguarda la numerosità abbiamo che:

- **Trainset:** 273 samples
- **Testset:** 118 samples

La **numerosità di questo dataset è un problema** al quale, per ovvio ragioni, non abbiamo potuto trovare rimedio alcuno. La suddivisione di attività nei due è dunque la seguente:




Figura 14: Suddivisione attività in train e test set

Ovviamente a livello di numerosità vige il fatto che nel training siamo dotati di più samples per ogni attività (data la numerosità); **non vi sono dunque situazioni di "aggregazione"** nella fase finale del periodo per quanto riguarda le attività. Tuttavia l'attività *Leaving* vede 16 samples nel training e 12 nel testing, tuttavia data l'osservazione (quindi l'*azione*) che causa tale attività non dovrebbero esserci problemi.

### 3.2.2 Performance

Abbiamo calcolato la **matrice di confusione**, da questa poi siamo andati a definire le principali misure di performance; in questa sezione mostreremo i risultati da noi ottenuti.

**Forward-Backward** Metodo di inferenza principale del nostro progetto, esegue un'**operazione di filtraggio** date le nuove osservazioni e un'**operazione di smoothing** su quelle precedenti al fine di "sistemare" le probabilità precedenti; **la finestra dello smoothing è pari a 15**. Utilizziamo questo metodo in quanto **vogliamo osservare come le probabilità** associate agli stati nascosti **mutino** durante l'intero processo; l'attività inferita risulterà poi essere quella con **probabilità maggiore**. Valutiamo la matrice di confusione:

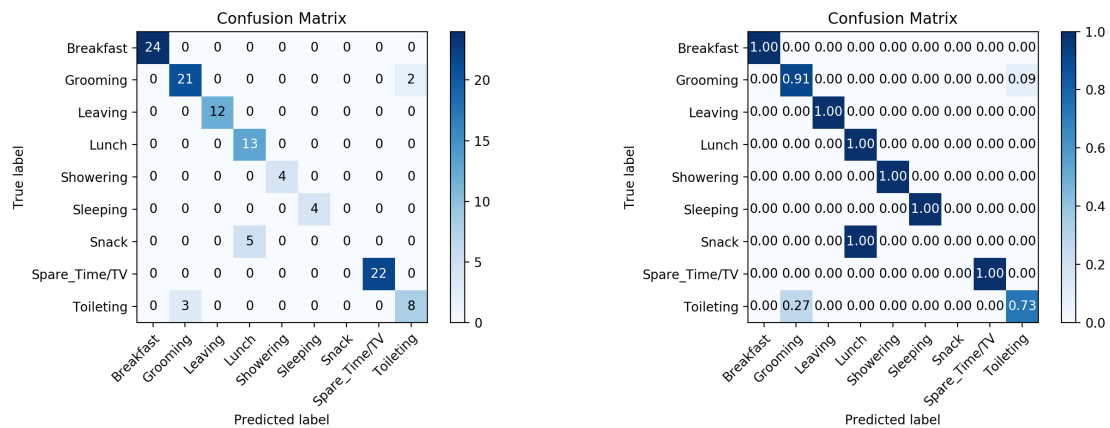


Figura 15: Versione normalizzata e non della matrice di confusione

Osserviamo che **problematica principale** risulta essere l'attività *Snack* la quale viene ripetutamente scambiata per *Lunch*; **le attività in questione condividono infatti i sensori della cucina**. Sembra non vi siano problematiche con l'attività *Breakfast*, tale situazione sarà dovuta dal fatto che l'individuo effettua un'azione solo in tale attività e dunque vincola tutte le seguenti e precedenti, inoltre è possibile sia dovuta anche dalla **probabilità di transizione molto alta** da *Showering* a *Breakfast*.

Altre **problematiche** sono registrate per le attività di *Toileting* e *Grooming* le quali vedono gli stessi sensori del bagno attivati. Tuttavia tale **situazione è molto limitata**. Forniamo le performance le quali saranno poi discusse:

Performance				
Attività	Precision	Recall	F1-Score	Quantità
Breakfast	1.00	1.00	1.00	24
Grooming	0.88	0.91	0.89	23
Leaving	1.00	1.00	1.00	12
Lunch	0.72	1.00	0.84	13
Showering	1.00	1.00	1.00	4
Sleeping	1.00	1.00	1.00	4
Snack	0.00	0.00	0.00	5
Spare_Time/TV	1.00	1.00	1.00	22
Toileting	0.80	0.73	0.76	11

**Precision** Per quanto riguarda la **precision** possiamo notare, come dalla matrice si poteva intendere, le **problematiche maggiori** riguardano l'attività *Snack* la quale **non viene mai identificata come tale**. Il resto delle attività vede un valore per questa performance accettabile e sempre superiore al 80%. Unico caso in cui è sul 72% è per l'attività *Lunch* situazione conseguenziale a *Snack*. Il valore medio, dato un approccio *macro average* è pari a 0.822.

**Recall** La **recall** sembra avere valori migliori, indice che inferiamo correttamente data una classe. Osserviamo che, tolta l'attività *Snack*, la **classe più problematica** risulta essere *Toileting* la quale vede delle azioni etichettate all'attività di *Grooming*. Anche per questa performance abbiamo valutato la media date le classi, la stessa è pari a 0.849.

**F1-Score** Quest'ultima misura volta al paragone tra diversi modelli è stata calcolata ma di fatto non risulta a noi essere molto utile, tuttavia possiamo notare come tendenzialmente ciò che è stato detto per le altre misure risulta essere relativamente rappresentato dal valore di tale indice. La *Macro average* è pari a 0.832.

**Accuracy** L'accuratezza, valutata date tutte le attività presenti, è pari a 0.9152; **valore molto alto**, il quale tuttavia nasconde le limitate capacità del nostro modello nei confronti della classe *Snack*

### 3.3 Casa B

#### 3.3.1 Numerosità Train set e Test set

Per quanto riguarda la **numerosità** dei set abbiamo la seguente situazione:

- **Trainset:** 914 samples
- **Testset:** 313 samples

A differenza del modello precedente abbiamo un **dataset molto più numeroso**, tale situazione va a vantaggio delle possibili situazioni osservabili durante la fase di training. Forniamo la suddivisione in percentuale delle attività date le azioni per entrambi i set:




Figura 16: Suddivisione attività in train e test set

In questo secondo dataset possiamo osservare come le attività, data la loro numerosità, **sia praticamente in entrambi i set equivalente**. Dunque l'attività di preprocessing, molto difficoltosa data questa abitazione, ha prodotto un insieme significativo di dati.

### 3.3.2 Performance

In maniera analoga a quanto fatto prima mostriamo i **risultati ottenuti** in fase di testing; mostrando dunque la matrice di confusione e le relative misure di performance su di questa calcolate.

**Forward-Backward** Le differenze di performance sono qui un po' più **accentuate** la principale causa di tale situazione è dovuta principalmente al **maggior dinamismo** registrato in questa seconda abitazione.

Analizziamo ora la matrice di confusione ottenuta, ricordiamo che per questo modello erano presenti **sensori diversi** (sono qui presenti sensori sulle porte); gli stessi causano, come più volte ripetuto, un maggior dinamismo in quanto **registrano i movimenti all'interno dell'abitazione**. Le matrici sono dunque le seguenti:




Figura 17: Versione normalizzata e non della matrice di confusione

Possiamo osservare come i diversi sensori montati in questa abitazione rendano **più difficoltosa l'attività di inferenza** del nostro modello, difatti pare fin da subito che il maggior dinamismo dell'individuo complichino e **peggiori in generale le performance**.

Possiamo osservare come la **problematica principale** sia dovuta alle attività svolte in **cucina**, le stesse condividono molti sensori e dunque risulta molto più semplice commettere, per tali attività, un errore. Risulta **molto problematica** l'inferenza per ciò che riguarda l'attività di *Dinner* e *Lunch*, addirittura per la prima non è registrata nessuna corretta inferenza; pare sia *Snack* l'attività con cui vengono etichettate maggiormente le attività in cucina.

Notiamo anche come spesso si tenda a classificare *Spare\_Time/TV* come *Breakfast*, questa è una **conseguenza dei nuovi sensori**; difatti, come mostrato nella sezione 1.2.2 queste due attività condividono i sensori sulle porte i quali vengono continuamente attivati dall'individuo monitorato.

Possiamo anche notare le **solite problematiche** per le attività di *Toileting* e *Grooming*.

Passiamo dunque alla valutazione delle performance:

Performance				
Attività	Precision	Recall	F1-Score	Quantità
Breakfast	0.95	0.45	0.62	44
Dinner	0.00	0.00	0.00	10
Grooming	0.87	0.67	0.76	49
Leaving	1.00	0.96	0.98	24
Lunch	0.50	0.09	0.15	23
Showering	1.00	1.00	1.00	4
Sleeping	0.74	1.00	0.85	29
Snack	0.47	1.00	0.64	36
Spare_Time/TV	0.81	0.95	0.87	130
Toileting	0.94	0.75	0.84	44

**Precision** Possiamo osservare fin da subito una **difficoltà generale maggiore** rispetto al precedente modello, tale situazione è dovuta principalmente dal fatto che **diversi sensori sono condivisi** e dunque la caratterizzazione di determinate attività è più complessa. Le uniche che riescono a reggere sono *Leaving* e *Showering*, la prima è attivata principalmente dall'apertura della porta di ingresso la seconda dall'utilizzo della doccia.

*Snack* ha il secondo valore più basso per tale misura (47%) in quanto **il modello tende ad etichettare tutte le azioni che osserva in cucina con questa classe**. Anche *Lunch* presenta un valore basso, questo perché è stato etichettato con tale attività delle azioni riconducibili a *Spare\_Time/TV*, probabilmente riguardavano i sensori delle porte.

Un **ulteriore valore che sentiamo di citare** riguarda quello associato a *Sleeping*, la suddetta attività difatti vede la sua presenza in azioni riconducibili a *Toileting*, *Spare\_Time/TV*, **Grooming** e **Breakfast**. Tale situazione è **giustificabile ancora una volta dai sensori sulle porte** che, nella fase di training, avranno registrato movimenti notturni e dunque in questa fase di testing hanno inferito scorrettamente.

**Per le restanti attività** i valori di tale misura di performance **sono accettabili**; il valore medio, calcolato mediante approccio *macro average* è pari a 0.728.

**Recall** Ancora una volta **maglia nera** sono le attività *Dinner* (per ovvie ragioni) e *Lunch* le quali vedono le azioni che le caratterizzano principalmente etichettate da *Snack*. Anche *Breakfast* non è immune da tale situazione e vede ben 15 azioni etichettate in maniera scorretta da *Snack*. Tale situazione è in parte dovuta a una **problematica di fondo**, difatti *Dinner* è l'attività che viene osservata meno volte nel periodo, di conseguenza le performance legata a questa sono del tutto inesistenti.

**Ulteriori problematiche** sono registrate sia per *Grooming* che per *Toileting*, per la prima osserviamo come si tenda ad etichettare le azioni riconducibili a *Spare\_Time/TV*, questo è probabilmente dovuto ai sensori sulle porte. Per *Toileting* il principale problema riguarda la confusione con *Grooming* e in forma minore *Sleeping* e *Spare\_Time/TV*.

**Per le restanti attività il valore è relativamente alto**, la media risulta essere pari a 0.687; tale valore è presumibilmente causato dalla tendenza a etichettare tutte le attività in cucina con *Snack*.

**F1-Score** Questa misura **rimane sulla scia delle precedenti**, possiamo dire che trovare un modello più performante su attività come *Lunch* e *Dinner* non sembra un'impresa troppo faticosa. Per il resto delle attività i valori sono relativamente alti.

**Accuracy** Il valore di accuratezza è pari a 0.7709, **accusiamo il fatto che vi siano sensori installati sulle porte** ma anche la misera capacità di inferenza sulle attività che avvengono in cucina.



## 4 Conclusioni e possibili sviluppi futuri

Il progetto ha permesso di toccare con mano i **modelli e le inferenze studiate durante il corso**, la fase di studio del problema ha evidenziato **diverse criticità per quanto riguardava il dataset iniziale**. Queste sono state superate ma hanno comunque richiesto un'attenzione particolare e un approccio non strettamente collegato all'obiettivo finale del progetto.

In ogni caso **ci riteniamo soddisfatti dei modelli finali** ottenuti per le due abitazioni, nella demo che verrà presentata mostreremo come questi effettivamente funzionino e rappresentino un valido strumento per poter inferire sulle attività svolte da un individuo monitorato. **Il modello legato alla Casa B presenta maggiori criticità** dovute principalmente ai differenti sensori che rendono la **realtà analizzata molto più dinamica**, questo perché registrano molti più movimenti dell'utente. Tuttavia per determinate attività osserviamo criticità di inferenza, principalmente per tutto ciò che avviene in cucina.

Nell'ottica del creare un modello il cui fine è *“prendersi cura”* di un individuo monitorato, **si potrebbe andare ad arricchire la semplice inferenza sull'attività con una serie di informazioni riguardanti la durata della stessa**. Per esempio, abbiamo notato che l'individuo della **Casa A** pare essere molto sedentario, sarebbe interessante valutare il tempo trascorso seduto in funzione di quello passato all'esterno; importanti valutazioni possono essere effettuate anche in funzione del sonno dell'individuo e alla durata di questo.

Mantenendo il modello HHM sarebbe interessante provare ad **aumentare il numero di osservazioni effettuabili**, andando ad inserire nell'attuale tripla, al fine di farla diventare una quadrupla, anche la fascia oraria di osservazione. In questo modo, ovviamente, il numero di osservazioni verrebbe quintuplicate (ipotizzando le fasce orarie: *Mattino, Mezzogiorno, Pomeriggio, Sera e Notte*); sarebbe quindi interessante **valutare le performance ed osservare i cambiamenti** applicando una logica di *paired T-Test* al fine di ottenere una certezza maggiore dell'effettivo miglioramento (o meno) delle performance.

Sarebbe altresì interessante valutare una **regola di Markov meno stringente** aumentando dunque il livello di questa la fine di cercare di migliorare le capacità di inferenza del modello.